
Projekt 3

Umsatzprognose und Datenanalyse mit KNIME

Projektdokumentation

Modul	Data Science / KNIME-Projekt
Hochschule	Technische Hochschule Mittelhessen
Semester	SoSe 2026
Gruppe	Kana Tezo, Moumani Tchokote, Pokem Tezo, Mamo Tiotsap
Dozent	Frank Kammer
Abgabedatum	06.07.2026

Kurzbeschreibung

In diesem Projekt werden Filial- und Umsatzdaten vorbereitet, bereinigt und analysiert. Der Schwerpunkt liegt auf einer nachvollziehbaren Datenvorbereitung, der Bewertung der Datenqualität sowie der Umsetzung mehrerer Analysen in KNIME.

Inhaltsverzeichnis

1	Einleitung	2
2	Datengrundlage	2
3	Datenvorbereitung und Datenqualität	3
3.1	Erste Prüfung der Datensätze	3
3.2	Bereinigung und Standardisierung der Daten	3
3.3	Zusammenführung zum finalen Analysedatensatz	4
3.4	Datenqualitätskennzahlen vor und nach der Bereinigung	4
4	Umsatzprognose mit XGBoost	6
4.1	Grundidee des XGBoost-Verfahrens	6
4.2	Aufbereitung der Daten für das Regressionsmodell	6
4.3	Training und Testaufteilung	7
4.4	Modellbewertung	7
5	Visualisierung und Erklärung des Modells	8
5.1	Vergleich von tatsächlichem und vorhergesagtem Umsatz	8
5.2	Verteilung und auffällige Fehler	9
5.3	Fehleranalyse nach Zeit und Filialtyp	10
5.4	Erklärung der Einflussfaktoren mit XGBoost	12
5.5	Zusammenfassung der Auswertung	12
6	Clustering der Filialen	13
6.1	Ziel des Clusterings	13
6.2	Vorbereitung der Daten	13
6.3	Durchführung in KNIME	13
6.4	Ergebnisse der Clusteranalyse	14
6.5	Interpretation und Antwort auf die Fragestellung	15
7	Grenzen und Fazit	16
7.1	Grenzen der Analyse	16
7.2	Fazit	16

1 Einleitung

In diesem Projekt werden Filial- und Umsatzdaten einer Einzelhandelskette mit KNIME untersucht. Ziel ist es nicht nur, die Daten zu importieren und einzelne Auswertungen zu erstellen, sondern aus fehlerbehafteten Rohdaten eine verlässliche Grundlage für eine Umsatzprognose aufzubauen. Dafür müssen die Daten zunächst verstanden, bereinigt und so aufbereitet werden, dass sie für ein Regressionsmodell und weitere Analysen sinnvoll verwendet werden können.

Der Arbeitsprozess folgt einem klaren Ablauf. Zuerst werden die beiden bereitgestellten Datensätze begutachtet und auf typische Qualitätsprobleme geprüft. Danach werden fehlende, unplausible oder uneinheitliche Werte in KNIME behandelt und die Umsatzdaten mit den Filialstammdaten zusammengeführt. Anschließend wird die Wirkung dieser Bereinigung anhand von Datenqualitätskennzahlen bewertet.

Auf dieser bereinigten Datenbasis werden anschließend die weiteren Aufgaben bearbeitet: die Grundidee von XGBoost wird eingeordnet, ein Modell zur Umsatzprognose vorbereitet und bewertet, wichtige Ergebnisse werden visualisiert und mit XAI-Methoden erklärt. Abschließend werden die Filialen mit einem Clustering-Verfahren verglichen, um zu prüfen, ob unterschiedliche Filialgruppen auch unterschiedliche Umsatzmuster zeigen.

2 Datengrundlage

Für das Projekt wurden zwei ursprüngliche Datensätze verwendet. Der erste Datensatz, `filialumsatz.csv`, enthält die tagesbezogenen Umsatzinformationen der einzelnen Filialen. Dazu gehören unter anderem der Umsatz, die Anzahl der Kunden, der Öffnungsstatus der Filiale sowie Informationen zu Aktionen, Feiertagen und Schulferien. Der zweite Datensatz, `filialen.csv`, beschreibt die eher stabilen Eigenschaften der Filialen, zum Beispiel den Filialtyp, das Sortiment, die Entfernung zum nächsten Wettbewerber und Informationen zu längerfristigen Promotion-Aktionen.

Beide Dateien erfüllen unterschiedliche Rollen. Die Umsatzdatei zeigt, was an einem bestimmten Tag in einer Filiale passiert ist. Die Filialdatei erklärt dagegen, welche strukturellen Eigenschaften diese Filiale besitzt. Für die späteren Analysen reicht deshalb keiner der beiden Datensätze allein aus. Erst durch die Zusammenführung entsteht ein Datensatz, der sowohl zeitabhängige Umsatzinformationen als auch feste Filialmerkmale enthält.

Tabelle 1: Überblick über die verwendeten Datensätze

Datensatz	Zeilen	Spalten	Inhalt
<code>filialumsatz.csv</code>	336.084	9	Tagesbezogene Umsatzdaten je Filiale, z.B. Umsatz, Kunden, Öffnung und Aktionen.
<code>filialen.csv</code>	406	10	Stammdaten der Filialen, z.B. Filialtyp, Sortiment, Wettbewerb und Promo2.
<code>fialialeclean.csv</code>	119.905	23	Bereinigter und zusammengeführter Analysedatensatz für die weiteren Aufgaben.

Für die Analyse sind vor allem die Variablen `Sales`, `Customers`, `Open`, `Promo`, `StoreType`, `Assortment`, `CompetitionDistance` und `PromoInterval` relevant. Sie beschreiben sowohl die tägliche Verkaufssituation als auch die Eigenschaften der einzelnen Filialen. Der bereinigte Datensatz `fialialeclean.csv` bildet anschließend die zentrale Grundlage für die Datenqualitätsbewertung, die Umsatzprognose mit XGBoost, die Visualisierung der Modellergebnisse und das Clustering der Filialen.

3 Datenvorbereitung und Datenqualität

3.1 Erste Prüfung der Datensätze

Zu Beginn wurden beide Rohdatensätze in KNIME importiert und mit einfachen Tabellen- und Statistikansichten untersucht. Dabei ging es zunächst darum, die Größe der Tabellen, die vorhandenen Spalten und die Beziehung zwischen `filialumsatz.csv` und `filialen.csv` zu verstehen. Gleichzeitig wurden erste Auffälligkeiten sichtbar, zum Beispiel fehlende Werte, unplausible Zahlenbereiche und uneinheitliche Schreibweisen.

3.2 Bereinigung und Standardisierung der Daten

Bei der Bereinigung wurden in beiden Rohdatensätzen mehrere konkrete Datenfehler gefunden. Ziel war es nicht, jeden Einzelfall ausführlich zu beschreiben, sondern die wichtigsten Fehlerarten zu erkennen und so zu behandeln, dass der finale Datensatz für Analyse und Modellierung stabil verwendbar ist.

- **`filialumsatz.csv`:** In den Umsatzdaten wurden unter anderem fehlende Werte in `Sales`, `Customers`, `Open` und `Promo` gefunden. Zusätzlich traten unplausible Werte wie negative Umsätze, Dummy-Werte wie 999999 und doppelte Einträge für dieselbe Filiale am selben Datum auf. Diese Fälle wurden in KNIME markiert, gefiltert oder regelbasiert korrigiert.
- **`filialumsatz.csv`:** Zusätzlich wurden logische Widersprüche geprüft, zum Beispiel Umsatz bei geschlossener Filiale oder Umsatz ohne Kunden. Solche Fälle wurden nicht als normale Beobachtungen übernommen, weil sie die spätere Umsatzprognose verfälschen könnten.

- **filialen.csv:** Kategoriale Variablen wurden vereinheitlicht. Unterschiedliche Schreibweisen von `StoreType`, zum Beispiel `A`, `Typ A` oder `StoreType_A`, wurden auf die Codes `a`, `b`, `c` und `d` normalisiert. Bei `Assortment` wurden Varianten wie `Basic` oder `Basic assortment` auf `a`, `b` und `c` zurückgeführt.
- **filialen.csv:** Außerdem wurden unvollständige Angaben zu Promotion- und Wettbewerbsinformationen geprüft. Ein Beispiel ist eine aktive `Promo2`-Aktion mit vorhandener Startwoche und Startjahr, aber fehlendem `PromoInterval`. Solche Fälle wurden fachlich geprüft und nicht einfach als `no_interval` übernommen.

Die wichtigsten KNIME-Knoten für diese Schritte waren *Rule Engine*, *String Manipulation*, *Missing Value*, *GroupBy*, *Duplicate Row Filter*, *Row Filter* und *Joiner*. Nach der Bereinigung wurden die beiden Datensätze über `Store` zusammengeführt.

3.3 Zusammenführung zum finalen Analysedatensatz

Nach der Bereinigung wurden die Umsatzdaten mit den Filialstammdaten zusammengeführt. Dadurch entstand ein finaler Analysedatensatz, der sowohl die tägliche Verkaufssituation als auch die Eigenschaften der jeweiligen Filiale enthält. Dieser Datensatz bildet die Grundlage für die anschließende Bewertung der Datenqualität und für die weiteren Analysen. Der vollständige KNIME-Workflow zur Datenvorbereitung befindet sich in den abgegebenen KNIME-Dateien (*siehe ZIP-Ordner*).

3.4 Datenqualitätskennzahlen vor und nach der Bereinigung

Zur Bewertung der Datenqualität wurden fünf Kennzahlen verwendet: Vollständigkeit, Eindeutigkeit, Plausibilität, Konsistenz und Standardisierung. Dabei wurde jeweils der Zustand der Rohdaten mit dem finalen bereinigten Datensatz verglichen.

Tabelle 2: Zentrale Datenqualitätsprobleme vor und nach der Bereinigung

Kennzahl / Prüfung			Rohdaten	Clean-Datensatz	Interpretation
Fehlende Werte in			56.459	0	Vollständigkeit wurde im finalen Datensatz erreicht.
<code>filialumsatz.csv</code>					
Fehlende Werte in			841	0	Stammdaten wurden für die Analyse vervollständigt.
<code>filialen.csv</code>					
Doppelte Store-Date-Einträge			1.125	0	Jede Filiale besitzt pro Datum nur noch einen Eintrag.
Unplausible Sales-Werte			1.218	0	Negative, Dummy- und Extremwerte wurden behandelt.
Unplausible Customers-Werte			1.018	0	Fehlerhafte Kundenzahlen wurden bereinigt.
Konsistenzverletzungen			1.532	0	Widersprüche zwischen Umsatz, Kunden und Öffnung wurden entfernt.
Uneinheitliche Kategorien	Katego-	vorhanden		0	<code>StoreType</code> , <code>Assortment</code> und <code>PromoInterval</code> wurden standardisiert.

Die Vollständigkeit wurde für beide Rohdatensätze separat berechnet:

$$\text{Vollständigkeit}_{\text{Umsatzdaten}} = 1 - \frac{56.459}{3.024.756} = 98,13 \%$$

$$\text{Vollständigkeit}_{\text{Filialdaten}} = 1 - \frac{841}{4.060} = 79,29 \%$$

Auch die Eindeutigkeit der Umsatzdaten wurde geprüft:

$$\text{Eindeutigkeit} = 1 - \frac{1.125}{336.084} = 99,67 \%$$

Für die Konsistenzprüfung wurden Zeilen gezählt, in denen Umsatz, Kundenanzahl und Öffnungsstatus logisch nicht zusammenpassten:

$$\text{Konsistenz} = 1 - \frac{1.532}{336.084} = 99,54 \%$$

Insgesamt zeigen die Kennzahlen, dass die Rohdaten zwar in vielen Bereichen bereits verwendbar waren, aber mehrere fachlich relevante Fehler enthielten. Nach der Bereinigung enthält der finale Datensatz für die geprüften Regeln keine fehlenden Werte, keine Duplikate und keine relevanten Konsistenzverletzungen mehr.

4 Umsatzprognose mit XGBoost

4.1 Grundidee des XGBoost-Verfahrens

Für die Umsatzprognose haben wir uns zunächst mit dem XGBoost-Verfahren beschäftigt, weil es häufig für strukturierte Tabellendaten eingesetzt wird. XGBoost ist ein Boosting-Verfahren, bei dem mehrere Entscheidungsbäume nacheinander trainiert werden. Jeder neue Baum versucht dabei, die Fehler der vorherigen Bäume zu reduzieren, sodass am Ende ein stärkeres Gesamtmodell entsteht.

Für unser Projekt ist XGBoost passend, weil die Umsatzdaten viele verschiedene Einflussgrößen enthalten, zum Beispiel Kundenanzahl, Öffnungsstatus, Promotionen, Wochentag, Filialtyp und Sortiment. Zwischen diesen Variablen und dem Umsatz sind nicht nur einfache lineare Zusammenhänge zu erwarten. Deshalb ist ein baumbasiertes Verfahren sinnvoll, da es auch komplexere Muster in den bereinigten Daten erkennen kann.

4.2 Aufbereitung der Daten für das Regressionsmodell

In dieser Aufgabe ging es darum, den Umsatz der Filialen vorherzusagen. Als Zielvariable haben wir deshalb **Sales** verwendet. Grundlage war der bereinigte Datensatz **fialialeclean.csv** mit 119.905 Zeilen und 23 Spalten.




Abbildung 1: KNIME-Workflow zur Aufbereitung, Modellierung und Bewertung des XGBoost-Modells

Für das Modell haben wir zuerst nur geöffnete Filialtage behalten (**Open_clean** = 1). Nach diesem Schritt blieben 99.483 Zeilen übrig. Geschlossene Tage wurden nicht verwendet, weil der Umsatz dort meistens 0 ist und das Modell dadurch wenig über das normale Umsatzverhalten lernt.

Ein wichtiger Punkt war die Auswahl der Eingabevariablen. Die Variable **Customers_final_round** wurde nicht verwendet, weil die zukünftige Kundenanzahl in einer echten Prognosesituation nicht sicher bekannt ist. **Open_clean** wurde ebenfalls entfernt, weil diese Spalte nach dem Filtern überall den gleichen Wert hatte. Die Spalte **Store** wurde im Hauptmodell nicht verwendet, da sie nur eine technische ID ist. Stattdessen haben wir mit echten Filialmerkmalen wie **StoreType_clean**, **Assortment_clean**, **CompetitionDistance_final** und Promotion-Informationen gearbeitet.

Kategoriale Variablen wie **StateHoliday_clean**, **StoreType_clean**, **Assortment_clean** und **PromoInterval_clean** wurden mit One-Hot-Encoding in numerische Variablen umgewandelt. Dadurch konnten sie vom XGBoost-Modell verarbeitet werden.

4.3 Training und Testaufteilung

Die Daten wurden nicht zufällig, sondern zeitlich getrennt. Alle Daten bis zum 31.05.2015 wurden für das Training verwendet, alle späteren Daten für den Test. Dadurch wurde die spätere Prognosesituation besser nachgebildet: Das Modell lernt aus der Vergangenheit und wird auf zukünftigen Daten geprüft. Am Ende enthielt der Trainingsdatensatz 92.592 Zeilen und der Testdatensatz 6.891 Zeilen.

4.4 Modellbewertung

► 1: Statistics  Flow Variables			
Rows: 7 Columns: 1			
☐	#	RowID	Prediction (Sales) .00 Number (Float)
☐	1	R ²	0.979
☐	2	mean ε	921.382
☐	3	mean s	7,595,517.984
☐	4	root mε	2,755.997
☐	5	mean s	318.572
☐	6	mean ε	0.139
☐	7	adjuste	0.979

Abbildung 2: Ergebnisse des XGBoost-Hauptmodells ohne Store

Zusätzlich haben wir ein Vergleichsmodell getestet, bei dem die Spalte **Store** als Eingabevariable beibehalten wurde. Dieses Modell hatte zwar ein leicht besseres R^2 und einen etwas niedrigeren RMSE, aber MAE und MAPE waren schlechter. Deshalb haben wir das Modell ohne **Store** als Hauptmodell gewählt. Es ist besser interpretierbar und erzielt die bessere durchschnittliche Fehlerqualität.

Insgesamt zeigt Aufgabe 5, dass mit dem bereinigten Datensatz eine sehr gute Umsatzprognose möglich ist. Die genauere Analyse der Modellfehler, der Visualisierungen und der wichtigsten

Einflussfaktoren wird anschließend in der nächsten Aufgabe betrachtet.

5 Visualisierung und Erklärung des Modells

Für die Auswertung wurde das trainierte XGBoost-Modell auf dem chronologisch getrennten Testdatensatz angewendet. Die tatsächlichen Umsätze wurden mit den vorhergesagten Werten verglichen. Zusätzlich wurden drei Fehlergrößen berechnet: der einfache Vorhersagefehler, der absolute Fehler und der prozentuale Fehler. Dadurch konnten sowohl die allgemeine Prognosequalität als auch auffällige Abweichungen untersucht werden.

5.1 Vergleich von tatsächlichem und vorhergesagtem Umsatz




Abbildung 3: Tatsächlicher Umsatz im Vergleich zum vorhergesagten Umsatz

Der Scatter Plot zeigt, dass das Modell die grundlegende Umsatzstruktur gut erfasst. Bei niedrigen und mittleren Umsätzen liegen die vorhergesagten Werte relativ nah an den tatsächlichen Werten. Damit bildet das Modell die allgemeine Richtung der Umsatzentwicklung zuverlässig ab.

Bei sehr hohen Umsätzen treten jedoch größere Abweichungen auf. Das Modell erkennt solche Umsatzspitzen grundsätzlich, kann sie aber nicht immer exakt treffen. Die größten Schwierigkeiten liegen somit nicht im normalen Umsatzbereich, sondern vor allem bei Extremwerten.

5.2 Verteilung und auffällige Fehler

Verteilung der absoluten Fehler




Abbildung 4: Verteilung der absoluten Vorhersagefehler

Das Histogramm zeigt, dass der überwiegende Teil der absoluten Fehler klein ist. Die meisten Beobachtungen liegen im ersten Fehlerbereich, während nur wenige Fälle sehr hohe Abweichungen aufweisen. Diese Ausreißer erklären, warum der RMSE stärker ausfällt als der MAE: Große Einzelabweichungen werden bei quadratischen Fehlermetriken besonders stark gewichtet.

Ergänzend wurden die größten Fehlerfälle separat betrachtet. Dabei zeigte sich, dass die höchsten absoluten Abweichungen vor allem bei sehr hohen tatsächlichen Umsätzen entstehen. Gleichzeitig können bei niedrigeren Umsätzen bereits kleinere absolute Abweichungen zu hohen prozentualen Fehlern führen. Deshalb wurden absolute und relative Fehler gemeinsam interpretiert.

5.3 Fehleranalyse nach Zeit und Filialtyp

Mittlerer absoluter Fehler nach Wochentag




Abbildung 5: Mittlerer absoluter Fehler nach Wochentag

Die Analyse nach Wochentag zeigt, dass die Fehlerhöhe zwischen den Tagen variiert. Besonders an DayOfWeek 2 und DayOfWeek 6 ist der mittlere absolute Fehler höher als an mehreren anderen Tagen. DayOfWeek 7 sollte wegen der sehr geringen Anzahl an Beobachtungen vorsichtig interpretiert werden. Insgesamt zeigt sich ein zeitlicher Einfluss, jedoch kein Hinweis auf eine grundsätzlich instabile Modellleistung.

Mittlerer absoluter Fehler nach Filialtyp




Abbildung 6: Mittlerer absoluter Fehler nach Filialtyp

Die Fehleranalyse nach Filialtyp zeigt, dass die Prognosequalität nicht für alle Filialtypen gleich ist. StoreType **a** weist den höchsten mittleren absoluten Fehler auf. StoreType **b** liegt ebenfalls relativ hoch, sollte aber wegen der deutlich geringeren Anzahl an Beobachtungen vorsichtig bewertet werden. StoreType **d** wird im Testdatensatz am stabilsten vorhergesagt.

Da der Filialtyp im Modell one-hot-kodiert wurde, wurde er für diese Auswertung nach der Vorhersage wieder in eine lesbare Kategorie zurückgeführt. Damit lässt sich nachvollziehen, ob bestimmte Filialtypen schwieriger vorherzusagen sind als andere.

5.4 Erklärung der Einflussfaktoren mit XGBoost

Wichtigste Einflussfaktoren laut XGBoost




Abbildung 7: Wichtigste Einflussfaktoren laut XGBoost

Die Feature Importance zeigt, welche Variablen das XGBoost-Modell besonders stark für die Umsatzprognose nutzt. Der wichtigste Einflussfaktor ist `CompetitionDistance_final`. Damit spielt die Entfernung zur nächsten Konkurrenzfiliale eine zentrale Rolle für die Vorhersage des Umsatzes.

Weitere wichtige Einflussgrößen sind `Promo_clean` sowie zeitliche Merkmale wie Kalenderwoche, Wochentag, Tag des Monats und Monat. Das Modell nutzt somit sowohl standortbezogene Informationen als auch Promotions- und Kalendereffekte. `Customers_final` wurde bewusst nicht verwendet, da diese Information bei einer realistischen zukünftigen Umsatzprognose nicht im Voraus bekannt wäre.

5.5 Zusammenfassung der Auswertung

Die Auswertung zeigt, dass das XGBoost-Modell insgesamt eine solide Umsatzprognose liefert. Die meisten Vorhersagefehler sind klein, während größere Abweichungen vor allem bei außergewöhnlich hohen Umsätzen auftreten. Die zusätzlichen Analysen nach Wochentag, Monat, Promotion und Filialtyp zeigen leichte Unterschiede in der Fehlerhöhe, aber keine extremen systematischen Abweichungen.

Das in KNIME erstellte Dashboard fasst die wichtigsten Sichten zur Modellbewertung zusammen. Für die fachliche Interpretation sind insbesondere die Fehlerverteilung, die auffälligen Extremfälle, die Unterschiede zwischen Filialtypen und die Feature Importance relevant.

6 Clustering der Filialen

6.1 Ziel des Clusterings

In dieser Aufgabe wurden die Filialen nicht mehr nur einzeln betrachtet, sondern nach ähnlichem Verhalten gruppiert. Damit sollte geprüft werden, ob alle Filialen ungefähr gleich funktionieren oder ob es Gruppen gibt, die sich beim Umsatz, bei der Stabilität oder bei der Wirkung von Promotionen unterscheiden.

Diese Frage ist auch für die Umsatzprognose wichtig. Wenn alle Filialen sehr ähnlich wären, würde ein gemeinsames Prognosemodell ausreichen. Wenn sich aber klare Gruppen zeigen, kann man zusätzlich testen, ob eigene Modelle für bestimmte Filialgruppen bessere Ergebnisse liefern.

6.2 Vorbereitung der Daten

Für das Clustering wurde wieder der bereinigte Datensatz verwendet. Zuerst wurden nur geöffnete Filialtage behalten, weil geschlossene Tage mit Umsatz 0 das normale Verkaufsverhalten verfälschen würden. Danach wurde die auffällige Filiale 765 entfernt, da sie im Vergleich zu den anderen Filialen einen extrem hohen Umsatz hatte und das Clustering zu stark beeinflusst hätte.

Anschließend wurden die Tagesdaten auf Filialebene zusammengefasst. Jede Filiale hatte danach nur noch eine Zeile. Dafür wurden unter anderem folgende Kennzahlen gebildet:

- durchschnittlicher Umsatz,
- durchschnittliche Kundenzahl,
- Umsatz pro Kunde,
- Umsatzenschwankung,
- Anteil der Promotionstage,
- Umsatzunterschied zwischen Tagen mit und ohne Promotion.

Vor dem k-Means-Clustering wurden die ausgewählten Variablen normalisiert. Das war notwendig, weil die Variablen unterschiedliche Skalen haben. Ohne Normalisierung hätte zum Beispiel der Umsatz die anderen Merkmale zu stark dominiert.

6.3 Durchführung in KNIME

Die Umsetzung in KNIME erfolgte Schritt für Schritt: Filtern der geöffneten Tage, Berechnung zusätzlicher Kennzahlen, Gruppierung nach Filiale, Normalisierung der Merkmale, k-Means-Clustering und anschließende Auswertung der Cluster. Für die Gruppierung wurde $k = 3$ verwendet, weil dadurch eine gut lesbare und fachlich interpretierbare Aufteilung entstand. Der vollständige KNIME-Workflow befindet sich in den abgegebenen KNIME-Dateien (*siehe ZIP-Ordner*).

6.4 Ergebnisse der Clusteranalyse

Die drei Cluster unterscheiden sich zunächst deutlich beim durchschnittlichen Umsatz:

Tabelle 3: Durchschnittlicher Umsatz und Anzahl der Filialen pro Cluster

Cluster	Durchschnittlicher Umsatz	Anzahl Filialen
cluster_0	6.151	199
cluster_1	9.472	99
cluster_2	6.100	101




Abbildung 8: Durchschnittlicher Umsatz pro Cluster




Abbildung 9: Filialgruppen in der PCA-Ansicht




Abbildung 10: Verteilung des Umsatzes nach Cluster

6.5 Interpretation und Antwort auf die Fragestellung

`cluster_1` hebt sich klar von den anderen Gruppen ab. Die Filialen in diesem Cluster haben mit ungefähr 9.472 einen deutlich höheren durchschnittlichen Umsatz. `cluster_0` und `cluster_2` liegen beim Umsatzniveau dagegen sehr nah beieinander. Ihre Trennung entsteht daher nicht hauptsächlich durch den durchschnittlichen Umsatz, sondern eher durch andere Merkmale wie Umsatzschwankung, Kundenzahl, Umsatz pro Kunde oder Promotion-Effekt.

Die PCA-Ansicht hilft dabei, die Filialgruppen zweidimensional darzustellen und die Trennung der

Cluster visuell zu prüfen. Der Boxplot zeigt zusätzlich, wie stark die Umsätze innerhalb der einzelnen Cluster streuen. Dadurch sieht man nicht nur die Mittelwerte, sondern auch die Verteilung innerhalb der Gruppen.

Unsere Antwort auf die Fragestellung ist deshalb: Ein gemeinsames Modell ist als Ausgangspunkt sinnvoll, weil das XGBoost-Modell bereits eine sehr gute Gesamtleistung erreicht hat. Die Clusteranalyse zeigt aber, dass besonders die umsatzstarken Filialen aus `cluster_1` ein eigenes Verhalten zeigen. Deshalb wäre es als nächster Schritt sinnvoll, zusätzlich getrennte Modelle pro Cluster zu testen und die Modellgüte mit dem gemeinsamen Modell zu vergleichen.

7 Grenzen und Fazit

7.1 Grenzen der Analyse

Eine Grenze des Projekts liegt darin, dass die Bereinigung teilweise auf fachlichen Regeln beruhte. Viele Fälle waren eindeutig, zum Beispiel fehlende Werte, doppelte Einträge oder negative Umsätze. Bei anderen Fällen musste aber entschieden werden, welche Korrektur am plausibelsten ist. Solche Entscheidungen können nicht immer vollständig überprüft werden, weil die reale Situation hinter den Rohdaten nicht bekannt ist.

Eine weitere Grenze betrifft die Umsatzprognose. Für ein realistisches Prognosemodell wurden bestimmte Variablen bewusst ausgeschlossen, zum Beispiel die Kundenzahl. Dadurch wird die Aufgabe realistischer, weil zukünftige Kundenzahlen im Voraus nicht sicher bekannt sind. Gleichzeitig verliert das Modell dadurch aber eine sehr starke erklärende Variable.

Außerdem enthält der Datensatz nicht alle möglichen Einflussfaktoren auf den Umsatz. Externe Faktoren wie Wetter, lokale Ereignisse, regionale Kaufkraft, Konkurrenzaktionen oder besondere wirtschaftliche Situationen konnten nicht berücksichtigt werden. Gerade bei sehr hohen Umsätzen oder ungewöhnlichen Verkaufstagen kann das zu größeren Abweichungen führen.

Auch beim Clustering gibt es Grenzen. Die Cluster hängen stark davon ab, welche Merkmale ausgewählt und wie sie normalisiert wurden. Die Gruppierung zeigt interessante Unterschiede zwischen den Filialen, sie ist aber keine endgültige Erklärung für alle Umsatzunterschiede.

7.2 Fazit

Insgesamt zeigt das Projekt, wie aus fehlerhaften Rohdaten Schritt für Schritt ein verwendbarer Analysedatensatz aufgebaut werden kann. Zuerst wurden die beiden ursprünglichen Dateien geprüft, bereinigt und zusammengeführt. Danach wurde die Datenqualität mit Kennzahlen bewertet. Dabei wurde sichtbar, dass die Bereinigung notwendig war, weil in den Rohdaten fehlende Werte, Duplikate, unplausible Werte und logische Widersprüche vorhanden waren.

Auf dieser Grundlage konnte anschließend ein XGBoost-Modell zur Umsatzprognose erstellt werden. Die Ergebnisse zeigen, dass mit dem bereinigten Datensatz eine sehr gute Prognose möglich ist. Gleichzeitig wurde durch die Fehleranalyse deutlich, dass das Modell besonders bei sehr hohen Umsätzen größere Schwierigkeiten hat.

Die Visualisierungen und die Feature Importance haben geholfen, das Modell besser zu verste-

hen. Dabei wurde sichtbar, dass nicht nur Promotionen und Kalenderinformationen wichtig sind, sondern auch strukturelle Filialmerkmale wie die Wettbewerbsdistanz.

Das Clustering der Filialen hat zusätzlich gezeigt, dass nicht alle Filialen gleich funktionieren. Besonders die umsatzstarken Filialen bilden eine eigene Gruppe. Deshalb ist ein gemeinsames Modell als Grundlage sinnvoll, aber als nächster Schritt könnten zusätzliche Modelle pro Cluster getestet werden.

Damit erfüllt das Projekt das Ziel, die Daten nicht nur technisch zu verarbeiten, sondern sie inhaltlich zu verstehen: von der Datenqualität über die Prognose bis hin zur Interpretation unterschiedlicher Filialgruppen.